



# Machine Learning e Visão Computacional


## Renato Sellaro Dorighello



# Regressão de Dados

Linear Simples e Múltipla

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$




## Objetivos de aprendizagem

- Compreender regressão linear simples e múltipla.
- Conhecer e aplicar métricas: MAE, MSE/RMSE e  $R^2$ .
- Implementar pipeline de regressão (scikit-learn).
- Interpretar coeficientes e analisar resíduos.
- Discutir limitações e quando regressão linear não é adequada.



## Regressão Linear Simples


- Modelo:  $y = \beta_0 + \beta_1 \cdot x + \varepsilon$
- A Regressão Linear tem por objetivo resumir o relacionamento entre duas ou mais variáveis por meio de uma reta, e assim usar o resultado da função dessa reta para estimar valores, quando conhecendo as variáveis que a afetam.



Fonte: Berland, 2007

## Regressão Linear Simples


- Modelo:  $y = \beta_0 + \beta_1 \cdot x + \varepsilon$
- $\beta_0$ : Representa a intersecção da reta com o eixo y.
- $\beta_1$ : Coeficiente angular da Reta
- X: Variável explicativa
- Y: Variável Resposta



Fonte: Berland, 2007

## Regressão Linear Múltipla

- Modelo:  $y = \beta_0 + \sum \beta_j \cdot x_j + \varepsilon$
- A regressão linear múltipla é uma técnica estatística que usamos a fim de modelar a relação linear entre **uma variável dependente contínua** e **múltiplas variáveis preditoras/independentes** que podem ser contínuas ou categóricas.
- A principal diferença entre as regressões lineares múltipla e simples é que, na simples, só usamos uma variável preditora. Por outro lado, na regressão linear múltipla, nós usamos duas ou mais variáveis preditoras.



Fonte: Battisti; Smolski, 2019



## Regressão Linear Múltipla

- **Multicolinearidade**
- **O que é:** Quando duas ou mais variáveis independentes são altamente correlacionadas.
- **Impacto:**
  - Coeficientes instáveis e pouco interpretáveis.
  - Pequenas variações nos dados podem gerar grandes mudanças nos  $\beta_j$ .
- **Como detectar:**
  - Matriz de correlação.
  - Fator de Inflação da Variância (VIF).
- **Mitigação:** Remover variáveis redundantes ou usar regularização (Ridge/Lasso)

## Regressão Linear Múltipla

- **Divisão de Dados: Treino e Validação**
- **Hold-out:**
  - Separar os dados em treino (ex.: 75%) e teste (25%).
  - Mais simples e rápido.
- **K-fold Cross-validation:**
  - Divide os dados em kkk partes.
  - Treina e valida kkk vezes, cada parte sendo validação uma vez.
  - Mais robusto para avaliar o desempenho médio.



## Métricas de avaliação

### MAE: Mean Absolute Error – Erro Absoluto Médio

- **O que mede:** A média da diferença absoluta entre os valores previstos pelo modelo e os valores reais.
- **Interpretação:** Indica, em média, o quanto as previsões estão distantes dos valores reais **em unidades da variável alvo** (sem considerar sinal positivo ou negativo).
- **Vantagem:** Fácil de interpretar, pois está na mesma unidade da variável predita.

- **Fórmula:**

$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$$

- **Exemplo:** Se o MAE = 3, significa que o modelo erra, em média, 3 unidades na previsão.

# Métricas de avaliação

## MSE (Mean Squared Error – Erro Quadrático Médio)

- **O que mede:** A média dos quadrados das diferenças entre valores previstos e reais.
- **Interpretação:** Penaliza mais fortemente erros grandes, já que as diferenças são elevadas ao quadrado.
- **Vantagem:** Útil quando se quer punir erros maiores de forma mais severa.

- **Fórmula:**

$$MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$$

## Métricas de avaliação

### RMSE (Root Mean Squared Error – Raiz do Erro Quadrático Médio)

- **O que mede:** A raiz quadrada do MSE.
- **Interpretação:** Possui a mesma unidade da variável alvo, facilitando a compreensão.
- **Vantagem:** Mais interpretável que o MSE, mantendo a penalização para grandes erros.
- **Fórmula:**

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}$$



# Métricas de avaliação

## **R<sup>2</sup> (Coeficiente de Determinação)**

- **O que mede:** A proporção da variância dos dados que o modelo consegue explicar.
- **Interpretação:** Indica quão bem o modelo se ajusta aos dados, variando de **0 a 1** (ou podendo ser negativo, se o modelo for pior que uma média simples).

- **Fórmula:**

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **Exemplo:**  $R^2 = 0,85$  significa que 85% da variação nos dados é explicada pelo modelo.

# Métricas de avaliação

- **Comparar Desempenho em Treino vs. Teste**
- Ao avaliar um modelo de regressão (ou qualquer modelo de ML), é essencial comparar as métricas **nos dados de treino e nos dados de teste** para identificar problemas de generalização.

## 1. Overfitting (Sobreajuste)

- **O que é:** Modelo aprende excessivamente os padrões (e até ruídos) dos dados de treino, perdendo capacidade de generalização.
- **Sinais:**
  - Métricas **muito boas** no treino (erro baixo,  $R^2$  alto).
  - Métricas **muito piores** no teste (erro alto,  $R^2$  baixo).
- **Consequência:** Modelo funciona bem apenas nos dados que já viu, mas falha em dados novos.
- **Causas comuns:** Modelo muito complexo, excesso de variáveis irrelevantes, pouco dado.

# Métricas de avaliação

- **Comparar Desempenho em Treino vs. Teste**
- Ao avaliar um modelo de regressão (ou qualquer modelo de ML), é essencial comparar as métricas **nos dados de treino e nos dados de teste** para identificar problemas de generalização.

## 2. Underfitting (Subajuste)

- **O que é:** Modelo é simples demais para capturar os padrões dos dados.
- **Sinais:**
  - Métricas ruins **tanto no treino quanto no teste**.
- **Consequência:** Modelo não aprende bem nem mesmo nos dados de treino.
- **Causas comuns:** Modelo pouco complexo, variáveis importantes ausentes, dados pouco representativos.



# Métricas de avaliação

- **Comparar Desempenho em Treino vs. Teste**
- Ao avaliar um modelo de regressão (ou qualquer modelo de ML), é essencial comparar as métricas **nos dados de treino e nos dados de teste** para identificar problemas de generalização.

## 3. Bom Ajuste

- **O que é:** Modelo consegue **equilibrar desempenho** entre treino e teste.
- **Sinais:**
  - Métricas próximas nos dois conjuntos.
  - Erros baixos o suficiente para o contexto do problema.

Limitações

# Quando Não Usar regressão Linear?



# Limitações

## Quando Não Usar regressão Linear?

### 1. Relação não linear

- A regressão linear **assume** relação linear entre preditores e variável-alvo.
- **Problema:** Relações curvilíneas ou complexas não são bem capturadas.
- **Alternativa:** Regressão polinomial, modelos baseados em árvores ou redes neurais.

### 2. Multicolinearidade forte

- Variáveis preditoras muito correlacionadas entre si → coeficientes instáveis.
- Dificulta interpretação e reduz confiabilidade das estimativas.



## Limitações

### Quando Não Usar regressão Linear?

#### 3. Outliers influentes

- Valores extremos podem distorcer os coeficientes e previsões.
- Pode ser necessário detectar e tratar antes de aplicar.

#### 4. Variáveis categóricas mal codificadas

- Regressão linear exige variáveis numéricas.
- Categóricas precisam de codificação adequada

## Referências

**DAMÁSIO, Bruno Figueiredo.** O que é regressão linear múltipla? Blog Psicometria Online, 2 mar. 2021. Disponível em: <https://www.blog.psicometriaonline.com.br/o-que-e-regressao-linear-multipla/>. Acesso em: 11 ago. 2025 blog.psicometriaonline.com.br;

**DUARTE, Ana.** Desvendando a Regressão Linear. *Alura*, 06 fev. 2022. Disponível em: <https://www.alura.com.br/artigos/desvendando-a-regressao-linear>. Acesso em: 11 ago. 2025. [alura.com.br+2alura.com.br+2](https://www.alura.com.br+2alura.com.br+2)

**BATTISTI, Iara Denise Endruweit; SMOLSKI, Felipe Micaíl da Silva.** *Software R: curso avançado*. Cerro Largo: Universidade Federal da Fronteira Sul (UFFS), 2019. Disponível em: <https://smolski.github.io/livroavancado/index.html>. Acesso em: 11 ago. 2025.