




Machine Learning e Visão Computacional

Renato Sellaro Dorighello



K-Nearest Neighbors (K-NN)





Objetivos de aprendizagem

- Compreender o funcionamento do algoritmo K-Nearest Neighbors (K-NN), apresentar as principais métricas de avaliação para problemas de classificação e discutir cenários de uso.

Introdução ao K-NN


- **Introdução ao K-NN**
- **Conceito:** Algoritmo baseado na proximidade entre amostras.
- **Funcionamento:**
 - Calcular a distância entre a nova amostra e todas as amostras de treino.
 - Selecionar os K vizinhos mais próximos.
 - A classe mais frequente entre eles é atribuída à nova amostra.






- Classifica o novo ponto conforme os pontos mais próximos (vizinhos)
- Se “K” em “K-nearest neighbors” é igual a 1, então usa-se o vizinho mais próximo para definir a categoria.
- A Categoria é **VERDE**
- Se K=11, então usaríamos os 11 vizinhos mais próximos
- Nesse caso, a categoria ainda seria **VERDE**






- Agora o ponto está em uma localização diferente.
- Se $K=11$ e a célula está entre duas ou mais categorias, escolhemos aquela que obter “mais votos”
- Neste caso:
 - 7 vizinhos próximos são **VERMELHOS**
 - 3 são **LARANJA**
 - 1 é **VERDE**




- Se $K=11$ e a célula está entre duas ou mais categorias, escolhemos aquela que obter “mais votos”
- Neste caso:
 - 7 vizinhos próximos são **VERMELHOS**
 - 3 são **LARANJA**
 - 1 é **VERDE**
- Como vermelho obteve “mais votos”, então a categoria designada é **VERMELHO**




Introdução ao K-NN

- **Distâncias comuns:** Euclidiana, Manhattan, Minkowski.
- **Distância Euclidiana**
- Medida de distância entre dois pontos em um espaço euclidiano, calculada pela raiz quadrada da soma das diferenças quadradas de suas coordenadas.



Introdução ao K-NN

- **Distâncias comuns:** Euclidiana, Manhattan, Minkowski.
- **Distância Manhattan**
- Soma das diferenças absolutas entre as coordenadas dos dois pontos em cada dimensão



Introdução ao K-NN

- **Distâncias comuns:** Euclidiana, Manhattan, Minkowski.
- **Distância Minkowski**
- métrica utilizada para medir a similaridade ou dissimilaridade entre duas séries temporais
- Calcula a soma das diferenças absolutas elevadas a uma determinada potência

$$d(x, y) = \left(\sum_{k=1}^n |x_k - y_k|^r \right)^{\frac{1}{r}}$$

Introdução ao K-NN

- **Parâmetro K:** Impacto no viés e variância.
- Não há um comum consenso em como determinar o melhor valor para “K”;
- É recomendável testar alguns valores antes de adotar um.
 - **K pequeno** → mais sensível a ruídos e ao efeito dos outliers.
 - **K grande** → mais genérico, pode perder detalhes específicos. Por exemplo, uma categoria com poucas amostras sempre vai perder para outras.

Métricas de Avaliação

Matriz de Confusão

- **True Positive (TP):** Verdadeiro Positivo, um acerto! O modelo prevê *corretamente* a classe positiva.
- **True Negative (TN):** Verdadeiro Negativo, um acerto! O modelo prevê *corretamente* a classe negativa.
- **False Positive (FP):** Falso Positivo, um erro! O modelo prevê *incorretamente* a classe positiva.
- **False Negative (FN):** Falso Negativo, um erro! O modelo prevê *incorretamente* a classe negativa.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP (Verdadeiro Positivo)	FP (Falso Positivo)
	Negativo (0)	FN (Falso Negativo)	TN (Verdadeiro Negativo)

Métricas de Avaliação

Matriz de Confusão

- Ferramenta de análise detalhada;
- 1 com 1 é um acerto da classe positiva
- 0 com 0 é um acerto da classe negativa.
- 1 com 0 e 0 com 1 representam erros.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP (Verdadeiro Positivo)	FP (Falso Positivo)
	Negativo (0)	FN (Falso Negativo)	TN (Verdadeiro Negativo)

Métricas de Avaliação

- **Accuracy (Acurácia):**
- Percentual de acertos;
- Forma mais intuitiva;
-

$$\text{Acurácia} = \frac{\text{Qtd Predições Corretas}}{\text{Qtd Total de Predições}}$$

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

Métricas de Avaliação

- **Accuracy (Acurácia):**
- Exemplo: Vamos supor que nós estamos construindo um modelo para prever se um tumor é maligno (classe Positiva 1) ou benigno (classe Negativa 0). Suponhamos que nossa base de treino tenha 100 exemplos, onde 91 são benignos (classe Negativa 0) e 9 tumores são malignos (classe Positiva 1).

91 Negativo, classe 0 (benigno) }
09 Positivo, classe 1 (maligno) } → Total de 100 exemplos

Métricas de Avaliação

- **Accuracy (Acurácia):**

.Após treinamento, temos:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{1 + 90}{1 + 90 + 1 + 8} = 0.91$$

Dos 91 tumores benignos, o modelo conseguiu prever corretamente 90 como benignos. Entretanto, dos 9 tumores malignos, o modelo conseguiu identificar apenas 1! Ou seja, 8 das 9 pessoas com tumores malignos não foram diagnosticadas corretamente pelo modelo.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
	Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **Precision (Precisão):** Proporção de positivos previstos que realmente são positivos.

$$\text{Precisão} = \frac{TP}{TP + FP}$$

Métricas de Avaliação

- Precision (Precisão).

$$\text{Precisão} = \frac{TP}{TP + FP} = \frac{1}{1 + 1} = 0.5$$

O modelo tem uma Precisão de 0.5. Em outras palavras, quando ele prevê que um tumor é maligno (classe Positiva 1), ele está correto 50% das vezes.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
	Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **Recall (Sensibilidade):** Proporção de positivos reais que o modelo conseguiu identificar.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Métricas de Avaliação

- Recall (Sensibilidade):

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{1}{1 + 8} = 0.11$$

Temos um Recall de 0.11 apenas. Isso quer dizer que o modelo só identifica corretamente 11% dos tumores malignos

Valores Reais

Valores Previstos

	Positivo (1)	Negativo (0)
Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **F1-score:** Média harmônica entre precisão e recall, útil para classes desbalanceadas.

$$\text{F1-Score} = \frac{2 * \text{Precisão} * \text{Recall}}{\text{Precisão} + \text{Recall}}$$

- O maior valor possível para o F1-Score é 1.0, indicando Precisão e Recall perfeitos, e o valor mínimo possível é 0.0.

Discussão: Quando usar K-NN?

- **Vantagens:**

- Simples de entender e implementar.
- Não requer treinamento explícito.

- **Desvantagens:**

- Custo alto para predição com grandes bases.
- Sensível a escalas diferentes (necessidade de normalização).
- Desempenho prejudicado em dados de alta dimensionalidade.

- **Aplicações:**

- Classificação de imagens.
- Recomendação baseada em similaridade.

Referências

JOSH STARMER. **StatQuest: K-nearest neighbors, Clearly Explained**. [Vídeo]. YouTube, 26 jun. 2017. Disponível em: <https://www.youtube.com/watch?v=HVXime0nQel>.;

SARAH. **Medidas de similaridade e dissimilaridade**. Medium, 13 fev. 2022. Disponível em: <https://medium.com/@sarahmbs/medidas-de-similaridade-e-dissimilaridade-479f3d5f64c6>.

PROGRAMAÇÃO DINÂMICA. **CLASSIFICAÇÃO com k-vizinhos mais próximos (K-NN) | Machine Learning #07**. [Vídeo]. YouTube, 2020. Disponível em: <https://www.youtube.com/watch?v=DeAuVrhKw58>.

LOPES, André. **Medidas de Performance: Modelos de Classificação**. *Brains.dev*, 9 jan. 2023. Disponível em: <https://brains.dev/2023/medidas-de-performance-modelos-de-classificacao/>.