




Machine Learning e Visão Computacional

Renato Sellaro Dorighello



Support Vector Machine (SVM)




Objetivos de aprendizagem

- Apresentar o funcionamento do algoritmo SVM, os conceitos de margem e vetores de suporte, bem como a extensão para problemas não linearmente separáveis via Kernel Trick.

Introdução ao SVM

- **Motivação:** problema de separação de classes em alta dimensão.
- **Conceito:** encontrar o hiperplano que separa as classes **com a maior margem possível**.
- **Hiperplano:** fronteira de decisão que divide as classes
- **Margem máxima:** distância entre o hiperplano e os pontos mais próximos de cada classe.
- **Vetores de suporte:** pontos que estão mais próximos da margem e determinam o hiperplano.




SVM Linear

- **Quando usar:** classes aproximadamente separáveis por uma reta/hiperplano.

- **Função de decisão:**

$$f(x) = w \cdot x + b$$

- **Interpretação geométrica:** busca a fronteira que maximiza a separação.



Fonte: Winston, 2010

Kernel SVM

- **Problema:** quando os dados não são linearmente separáveis.
- **Solução:** usar funções de transformação de espaço (kernels).
- **Kernel Trick:** permite projetar dados em espaços de maior dimensão sem cálculo explícito.
- **Tipos comuns de kernels:**
 - Linear.
 - Polinomial.
 - Radial Basis Function (RBF).
 - Sigmóide.

Parâmetros Importantes

- **C (regularização):**

- Controla o equilíbrio entre margem larga e classificação correta de todos os pontos.
- C pequeno $\rightarrow$ margem maior, mais tolerante a erros.
- C grande $\rightarrow$ margem menor, tenta classificar tudo corretamente (pode causar overfitting).

- **γ (gamma, no kernel RBF):**

- Define alcance da influência de cada ponto de treino.
- γ baixo $\rightarrow$ fronteira mais suave.
- γ alto $\rightarrow$ fronteira mais complexa, pode superajustar.

Métricas de Avaliação

Matriz de Confusão

- **True Positive (TP):** Verdadeiro Positivo, um acerto! O modelo prevê *corretamente* a classe positiva.
- **True Negative (TN):** Verdadeiro Negativo, um acerto! O modelo prevê *corretamente* a classe negativa.
- **False Positive (FP):** Falso Positivo, um erro! O modelo prevê *incorretamente* a classe positiva.
- **False Negative (FN):** Falso Negativo, um erro! O modelo prevê *incorretamente* a classe negativa.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP (Verdadeiro Positivo)	FP (Falso Positivo)
	Negativo (0)	FN (Falso Negativo)	TN (Verdadeiro Negativo)

Métricas de Avaliação

Matriz de Confusão

- Ferramenta de análise detalhada;
- 1 com 1 é um acerto da classe positiva
- 0 com 0 é um acerto da classe negativa.
- 1 com 0 e 0 com 1 representam erros.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP (Verdadeiro Positivo)	FP (Falso Positivo)
	Negativo (0)	FN (Falso Negativo)	TN (Verdadeiro Negativo)

Métricas de Avaliação

- **Accuracy (Acurácia):**
- Percentual de acertos;
- Forma mais intuitiva;
-

$$\text{Acurácia} = \frac{\text{Qtd Predições Corretas}}{\text{Qtd Total de Predições}}$$

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

Métricas de Avaliação

- **Accuracy (Acurácia):**
- Exemplo: Vamos supor que nós estamos construindo um modelo para prever se um tumor é maligno (classe Positiva 1) ou benigno (classe Negativa 0). Suponhamos que nossa base de treino tenha 100 exemplos, onde 91 são benignos (classe Negativa 0) e 9 tumores são malignos (classe Positiva 1).

91 Negativo, classe 0 (benigno) }
09 Positivo, classe 1 (maligno) } → Total de 100 exemplos

Métricas de Avaliação

- **Accuracy (Acurácia):**

.Após treinamento, temos:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{1 + 90}{1 + 90 + 1 + 8} = 0.91$$

Dos 91 tumores benignos, o modelo conseguiu prever corretamente 90 como benignos. Entretanto, dos 9 tumores malignos, o modelo conseguiu identificar apenas 1! Ou seja, 8 das 9 pessoas com tumores malignos não foram diagnosticadas corretamente pelo modelo.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
	Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **Precision (Precisão):** Proporção de positivos previstos que realmente são positivos.

$$\text{Precisão} = \frac{TP}{TP + FP}$$

Métricas de Avaliação

- Precision (Precisão).

$$\text{Precisão} = \frac{TP}{TP + FP} = \frac{1}{1 + 1} = 0.5$$

O modelo tem uma Precisão de 0.5. Em outras palavras, quando ele prevê que um tumor é maligno (classe Positiva 1), ele está correto 50% das vezes.

		Valores Reais	
		Positivo (1)	Negativo (0)
Valores Previstos	Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
	Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **Recall (Sensibilidade):** Proporção de positivos reais que o modelo conseguiu identificar.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Métricas de Avaliação

- Recall (Sensibilidade):

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{1}{1 + 8} = 0.11$$

Temos um Recall de 0.11 apenas. Isso quer dizer que o modelo só identifica corretamente 11% dos tumores malignos

Valores Reais

Valores Previstos

	Positivo (1)	Negativo (0)
Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

Métricas de Avaliação

- **F1-score:** Média harmônica entre precisão e recall, útil para classes desbalanceadas.

$$\text{F1-Score} = \frac{2 * \text{Precisão} * \text{Recall}}{\text{Precisão} + \text{Recall}}$$

- O maior valor possível para o F1-Score é 1.0, indicando Precisão e Recall perfeitos, e o valor mínimo possível é 0.0.

Discussão: Quando usar SVM?

- **Vantagens:**

- Bom em alta dimensionalidade.
- Robusto a overfitting em muitos casos.
- Versátil via kernels.

- **Desvantagens:**

- Difícil interpretar coeficientes em alta dimensão.
- Lento em datasets muito grandes.

- **Aplicações:**

- Reconhecimento de imagens.
- Bioinformática (classificação de genes).
- Texto e processamento de linguagem natural.

Referências

JAIN, Abhishek. **Kernels SVM e seu tipo**. Disponível em: <https://medium.com/@abhishekjainindore24/svm-kernels-and-its-type-dfc3d5f2dcd8> ;

SARAH. **Medidas de similaridade e dissimilaridade**. Medium, 13 fev. 2022. Disponível em: <https://medium.com/@sarahmbs/medidas-de-similaridade-e-dissimilaridade-479f3d5f64c6>.

PROGRAMAÇÃO DINÂMICA. **CLASSIFICAÇÃO com Máquinas de Vetores de Suporte (SVM) | Machine Learning #05**. [Vídeo]. YouTube, 2020. Disponível em: <https://www.youtube.com/watch?v=ba7tMJZbGyA>.

AULAS DE COMPUTAÇÃO . **SVM - Máquina de Vetores de Suporte**. [Vídeo]. YouTube, 2021 Disponível em: <https://www.youtube.com/watch?v=7y4uceXgYeo&t=625s>.

WINSTON, Patrick H. Lecture 16: Learning: Support Vector Machines. In: *Artificial Intelligence (6.034) – Fall 2010*. Dept. of Electrical Engineering and Computer Science, Massachusetts Institute of Technology. MIT OpenCourseWare, [material de leitura em PDF / vídeo]. Disponível em: https://ocw.mit.edu/courses/6-034-artificial-intelligence-fall-2010/resources/mit6_034f10_svm/.