

AVALIAÇÃO - Redes Neurais

Maria Eduarda Selhorst
Yasmim Trembulack Agostinho

Professor: Paulo Sergio da Conceição Moreira

5º Período – Engenharia de Software - Campus São José dos Pinhais

1. Diagnóstico de câncer de mama

1.1. Tabela comparativa dos cenários testados:

	Modelo	Neurônios	Ativação	Normalização	Épocas	Accuracy
1	Perceptron	Nenhum	Nenhuma	Sim	1000	0.982
2	Perceptron	Nenhum	Nenhuma	Sim	200	0.982
3	MLP	30	relu	Sim	150	0.994
4	MLP	50, 30	relu	Sim	1000	0.982
5	MLP	30	tanh	Sim	1000	0.988
6	MLP	30	relu	Não	1000	0.942

1.2. Relatórios de Desempenho:

Cenário 1:

O modelo Perceptron apresentou uma accuracy de 0.982, com um f1-score médio ponderado de aproximadamente 0.98. Os valores de precision e recall foram elevados para ambas as classes (malignant e benign), demonstrando que, mesmo sendo um modelo linear simples, o Perceptron teve um bom desempenho neste conjunto de dados.

Cenário 3 ✓ Melhor configuração:

Este foi o modelo que apresentou o melhor desempenho geral, atingindo uma accuracy de 0.994. Os valores de precision, recall e f1-score ficaram muito próximos de 1 para ambas as classes, indicando excelente capacidade de generalização e separação entre as classes. O uso da normalização foi essencial para esse bom resultado.

Cenário 6:

Neste cenário, a ausência da normalização impactou negativamente o desempenho do modelo, que obteve uma accuracy de apenas 0.942. Houve uma queda significativa no recall da classe "malignant", o que é particularmente problemático para problemas médicos, onde falsos negativos devem ser minimizados.

Cenários Intermediários (2, 4 e 5):

Os demais cenários apresentaram resultados semelhantes ao Cenário 1, com pequenas variações nos valores de accuracy e f1-score. O uso de duas camadas ocultas (Cenário 4) não trouxe ganhos em relação à versão mais simples (Cenário 3), enquanto o uso da função de ativação *tanh* (Cenário 5) obteve desempenho um pouco inferior ao *ReLU*.

2. Reconhecimento de dígitos

2.1. Tabela comparativa dos cenários testados:

	Modelo	Neurônios	Ativação	Normalização	Épocas	Accuracy
1	Perceptron	Nenhum	Nenhuma	Não	1000	0.9222
2	Perceptron	Nenhum	Nenhuma	Sim	1000	0.9314
3	MLP	30	relu	Sim	200	0.9759
4	MLP	50, 30	relu	Sim	1000	0.9759
5	MLP	50	tanh	Sim	1000	0.9796

2.2. Relatórios de Desempenho:

Cenário 1:

O modelo Perceptron, sem normalização, atingiu uma accuracy de 0.9222. Apesar de ser um modelo linear simples, conseguiu um desempenho inicial razoável no reconhecimento de dígitos, mesmo sem qualquer pré-processamento dos dados.

Cenário 2:

Com a aplicação da normalização, o mesmo Perceptron elevou sua accuracy para 0.9314. Embora o ganho não tenha sido expressivo, mostra que a normalização pode trazer uma leve melhora mesmo para modelos lineares, ao uniformizar as escalas das variáveis de entrada.

Cenário 3:

Utilizando uma rede MLP com uma camada oculta de 30 neurônios e ativação ReLU, com normalização e 200 épocas, a accuracy subiu para 0.9759. Este resultado evidencia como a introdução de não linearidade e um bom pré-processamento permitem ao modelo capturar padrões mais complexos no conjunto de dados.

Cenário 4:

Ao aumentar a complexidade da rede para duas camadas ocultas (50 e 30 neurônios), ativação ReLU e 1000 épocas, a accuracy permaneceu em 0.9759, sem ganhos adicionais. Isso sugere que a arquitetura anterior já era suficiente para modelar o problema, e que o aumento da complexidade não trouxe melhorias relevantes neste caso.

Cenário 5 ✓ Melhor configuração:

Com uma MLP de uma única camada com 50 neurônios, ativação tanh, normalização e 1000 épocas, o modelo alcançou a melhor accuracy geral de 0.9796. Isso indica que, para

este conjunto de dados, a função de ativação tanh conseguiu proporcionar uma leve superioridade em relação ao ReLU, obtendo o melhor desempenho entre todas as configurações testadas.

3. Previsão da progressão da diabetes

3.1. Tabela comparativa dos cenários testados:

	Modelo	Neurônios	Ativação	Normalização	Épocas	MSE	MAE	R ²
1	MLP	30	relu	Sim	300	15639.87	107.23	-1.897
2	MLP	50, 30	relu	Sim	500	2991.49	43.24	0.446
3	MLP	100	tanh	Sim	1000	3456.98	47.44	0.360
4	MLP	100, 50	tanh	Sim	1000	7840.92	67.12	-0.452
5	MLP	50	logistic	Sim	500	16723.52	109.66	-2.098
6	MLP	30	relu	Não	1000	6275.52	60.80	-0.162

3.2. Relatórios de Desempenho:

Cenário 1:

A rede com uma única camada de 30 neurônios e apenas 300 épocas teve desempenho muito ruim, com R² negativo (-1.897) e MAE elevado (107.23), mostrando que o modelo não conseguiu capturar a complexidade dos dados.

Cenário 2 ✓ Melhor configuração:

O modelo com duas camadas ocultas (50, 30) e ativação ReLU foi o que apresentou melhor desempenho geral, atingindo um R² de 0.446, MSE de 2991.49 e MAE de 43.24. O uso da normalização foi crucial para alcançar esses resultados e evitar divergência ou aprendizado deficiente.

Cenário 3:

Apesar de ter alcançado um desempenho razoável (R² = 0.360), o modelo com 100 neurônios e ativação tanh teve erro absoluto maior que o melhor modelo. Ainda assim, foi superior a outras arquiteturas com tanh.

Cenário 4:

Apesar da complexidade (2 camadas ocultas), o desempenho foi ruim, com R^2 negativo (-0.452). A combinação de tanh com camadas profundas não foi eficaz nesse caso.

Cenário 5:

A ativação logistic resultou no pior desempenho entre todos os modelos testados (R^2 = -2.098), confirmando que essa função costuma ter dificuldades em tarefas de regressão, especialmente com muitos dados contínuos.

Cenário 6:

Neste cenário, a falta de normalização impactou fortemente o resultado, resultando em um R^2 negativo (-0.162) mesmo com 1000 épocas. Isso demonstra que a normalização dos dados é fundamental para redes neurais aprenderem corretamente.

4. Previsão de preços de casas na Califórnia

4.1. Tabela comparativa dos cenários testados:

	Modelo	Neurônios	Ativação	Normalização	Épocas	MSE	MAE	R^2
1	MLP	30	relu	Sim	300	0.3060	0.3785	0.7668
2	MLP	50,30	relu	Sim	500	0.2777	0.3675	0.7883
3	MLP	100	tanh	Sim	1000	0.3005	0.3848	0.7710
4	MLP	50	logistic	Sim	500	0.3012	0.3844	0.7704
5	MLP	30	relu	Não	1000	0.5476	0.5574	0.5827

4.2. Relatórios de Desempenho:

Cenário 1:

O modelo MLP com uma camada oculta de 30 neurônios, função de ativação ReLU, normalização e 300 épocas apresentou um desempenho satisfatório, com MSE de 0.3060, MAE de 0.3785 e um R^2 de 0.7668. Esses resultados indicam uma boa capacidade de ajuste, embora ainda haja espaço para melhorias, principalmente na redução dos erros.

Cenário 2 ✓ Melhor configuração:

A configuração com duas camadas ocultas (50 e 30 neurônios), ativação ReLU, normalização e 500 épocas foi a que obteve o melhor desempenho entre os cenários testados. O modelo atingiu um MSE de 0.2777, MAE de 0.3675 e R^2 de 0.7883, explicando cerca de 79% da variabilidade dos dados. O acréscimo de uma segunda camada e o aumento do número de épocas contribuíram positivamente para a capacidade preditiva do modelo.

Cenário 3:

Nesta configuração, foi utilizado um MLP com uma única camada de 100 neurônios, ativação tanh, normalização e 1000 épocas. O modelo apresentou MSE de 0.3005, MAE de 0.3848 e R^2 de 0.7710. Embora o desempenho tenha melhorado em relação ao Cenário 1, ainda ficou abaixo da melhor configuração (Cenário 2), sugerindo que o aumento de neurônios com tanh teve efeito positivo, mas limitado.

Cenário 4:

Com uma camada de 50 neurônios, ativação logística, normalização e 500 épocas, o modelo obteve MSE de 0.3012, MAE de 0.3844 e R^2 de 0.7704. O desempenho foi semelhante ao Cenário 3, mas um pouco inferior. Isso indica que, para este problema, a ativação logística não conseguiu superar as funções ReLU ou tanh.

Cenário 5:

Sem aplicar normalização, o modelo com 30 neurônios, ativação ReLU e 1000 épocas apresentou queda acentuada no desempenho, com MSE de 0.5476, MAE de 0.5574 e R^2 de 0.5827. Esses resultados confirmam a importância da normalização dos dados em redes neurais, principalmente em problemas de regressão, já que a ausência dela prejudicou significativamente a capacidade de ajuste do modelo.